SK네트웍스 Family AI과정 14기

데이터 수집 및 저장 수집 데이터 보고서

산출물 단계	데이터 수집 및 저장
평가 산출물	수집 데이터 보고서
제출 일자	2025.10.01
깃허브 경로	SKN14-Final-1Team
작성 팀원	김준기, 김재우, 안윤지, 이나경, 이원지희, 정민영

1. 수집 데이터 개요

데이터명	수집 대상	수집 목적	사용 예정 기능	출처/저작권
Google API Docs	Google API Docs 의 11개 API 공식 문서	RAG 챗봇 데이터로 활용, 벡터 DB 저장 및 검색	유사도 +키워드 검색, 문맥 기반 질의응답	Google for developers
회사 사내 문서	프론트엔드팀 15장 백엔드팀 15장 DATA&AI팀 15장 CTO 15장	파인튜닝 모델 학습, 사내용 RAG 챗봇 데이터로 활용	사내 규정 기반 지침 QA, 권한 기반 문서 검색, 팀 운영 문서	합성 데이터셋 (자체 생성)

2. 수집 방법 및 자동화 절차

- 수집 방식
  - Google api 문서 : 웹 크롤링 → 텍스트 추출 → 텍스트 파일 저장
  - 사내문서 : OpenAI API 프롬프트 합성 → 텍스트 파일 저장
- 수집 도구 또는 스크립트 설명:
  - 사용한 언어/라이브러리

    - 구글 API 문서 크롤링 : python, Selenium, lxml, beautifulsoup 등

    - 사내 내부 문서 : python, openai 등

- 예시 스크립트 또는 흐름도 첨부 (이미지, 순서도 또는 코드)

[구글 api 문서]

- 구글 API 문서 웹 크롤링 흐름
  - 시작 URL 설정 : 크롤링할 API 문서 URL을 설정하고, Selenium WebDriver를 실행
  - 링크 수집 : 상단바, 사이드바 링크를 모아 전체 문서 목록 확보
  - 본문 추출 : 각 문서의 본문(article)과 탭 콘텐츠 수집
    - 출처 URL 함께 저장
  - 파일 저장 : .txt 형식으로 로컬 폴더에 정리

=> 이 흐름으로 총 11개의 Google API 문서를 크롤링함

- 구글 API 문서 Selenium 웹 크롤링 코드

```
try:
    full_start_url = ensure_hl_ko(urljoin(BASE_URL, START_URL))
    driver.get(full_start_url)

    print("사이드바의 링크를 수집 중…")
    urls_to_crawl = collect_sidebar_links()
    urls_to_crawl.insert(0, full_start_url)
    # 중복 제거
    urls_to_crawl = sorted(list(dict.fromkeys(urls_to_crawl)))
    print(f"총 {len(urls_to_crawl)}개의 유효한 페이지 링크를 수집했습니다.")

    for i, url in enumerate(urls_to_crawl, 1):
        try:
            print(f"\n({i}/{len(urls_to_crawl)}) 크롤링 중: {url}")
            driver.get(url)

            try:
                article_element = wait.until(EC.presence_of_element_located((By.TAG_NAME, "article")))
            except TimeoutException:
                # 폴백
                article_element = wait.until(EC.presence_of_element_located((By.TAG_NAME, "body")))

            final_page_text = extract_page_text()

            # 파일 저장
            path = url.split("?")[0].replace(BASE_URL, "")
            filename = re.sub(r'[/\\?%*:|"<>]', "_", path).strip("_") + ".txt"
            filepath = os.path.join(OUTPUT_DIR, filename)

            with open(filepath, "w", encoding="utf-8") as f:
                f.write(f"Source URL: {url}\n\n{final_page_text}")
            print(f"저장 완료: {filepath}")

        except Exception as e:
            print(f"페이지 처리 중 오류 발생: {url} - {e}")

        time.sleep(0.8)

finally:
    driver.quit()
    print("\n크롤링 완료! 브라우저를 종료합니다.")
```

[기업 내부 문서]

- 사내 내부 문서 OPENAI API 생성 흐름
  - **문서 사양 정의** : 부서별로 15개씩 카테고리·제목을 리스트에 정리
  - **프롬프트 생성** : 각 문서 사양에 맞춰 실행 지침과 섹션 구조를 포함한 프롬프트 작성
  - **OpenAI API 호출** : 프롬프트를 넣어 문서 본문을 생성
  - **파일 저장** : 생성된 문서를 직급/제목 규칙에 맞게 .txt 파일로 저장
  - **인덱스 집계** : 생성된 파일 목록을 INDEX.txt로 정리
  - **반복 구조** : 부서별(4개) × 문서별(15개) 루프를 돌며 전체 60개 문서를 자동 생성

- 사내 내부 문서 OPENAI API 생성 프롬프트 코드

```
63  def make_user_prompt(category: str, title: str, today: str) -> str:
64      base = f"""# {title}
65  (분류: {category}) | 회사: CodeNova | 버전: v1.0 | 작성일: {today}
66
67  ---
68  **작성 지침**
69  - 언어: 한국어, Markdown 형식
70  - 분량: A4 1장(약 550~750단어) 내외
71  - CTO가 전략·리스크 관점에서 참고할 수 있도록 작성
72  - 실행 단계/체크리스트/의사결정 포인트 포함
73  """
74      if category == "인사·조직 기밀":
75          body = dedent(
76              """
77              ## 포함 섹션
78              1. 개요 및 목적
79              2. 적용 범위/대상
80              3. 실행 계획 (단계별)
81              4. 리스크 및 대응 방안
82              5. 검증 포인트 (CTO 관점)
83              6. 기밀 유지 지침
84              7. 개정 이력 (v1.0 – 오늘)
85          """
86          ).strip()
```

3. 데이터 설명 및 구성

✔️ 파일 및 필드 설명

- **구글 API 문서** : txt 파일 (문서 상단에 Source URL)

```
Source URL: https://cloud.google.com/firestore/docs/security/rules-structure?hl=ko
Title: 보안 규칙 구조화

의견 보내기

컬렉션을 사용해 정리하기

내 환경설정을 기준으로 콘텐츠를 저장하고 분류하세요.

보안 규칙 구조화

Firestore 보안 규칙을 통해 데이터베이스의 문서와 컬렉션에 대한 액세스를 제어할 수 있습니다. 유연한 규칙 구문을 사용하면 전체 데이터베이스에 대한 모든 쓰기 작업부터 특정 문서에 대한 작업까지 어떠한 상황에 맞는 규칙이라도 작성할 수 있습니다.

이 가이드에서는 보안 규칙의 기본적인 구문과 구조를 설명합니다. 이 구문과 보안 규칙 조건 [https://cloud.google.com/firestore/native/docs/security/rules-conditions?hl=ko]을 결합하면 완전한 규칙 세트가 생성됩니다.

참고: 서버 클라이언트 라이브러리는 모든 Firestore 보안 규칙을 우회하고 대신 Google 애플리케이션 기본 사용자 인증 정보 [https://cloud.google.com/docs/authentication/production?hl=ko]를 통해 인증합니다.
서버 클라이언트 라이브러리, REST 또는 RPC API를 사용하는 경우 Firestore용 Identity and Access Management (IAM) [https://cloud.google.com/firestore/docs/security/iam?hl=ko]를 설정해야 합니다.

서비스 및 데이터베이스 선언

Firestore 보안 규칙은 항상 다음 선언으로 시작됩니다.
service cloud.firestore {
match /databases/{database}/documents {
allow write: if <condition>;
service cloud.firestore {
match /databases/{database}/documents {

Firestore의 데이터는 문서 컬렉션으로 정리되며, 각 문서는 하위 컬렉션을 통해 계층구조를 이룰 수 있습니다. 계층적 데이터에 보안 규칙이 어떻게 적용되는지 이해하는 것이 중요합니다.
```

- **사내 내부 문서** : 아래와 같이 직급별 폴더 안에 문서별 **txt** 파일 존재

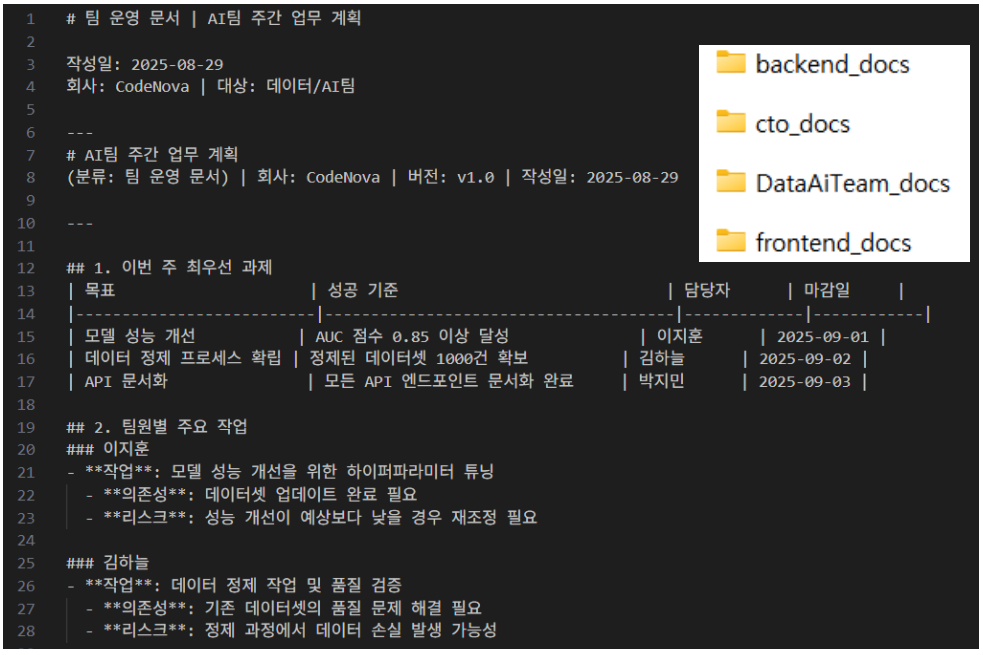

```
# 팀 운영 문서 | AI팀 주간 업무 계획

작성일: 2025-08-29
회사: CodeNova | 대상: 데이터/AI팀

---
# AI팀 주간 업무 계획
(분류: 팀 운영 문서) | 회사: CodeNova | 버전: v1.0 | 작성일: 2025-08-29

---

## 1. 이번 주 최우선 과제
| 목표                    | 성공 기준                              | 담당자      | 마감일      |
|-------------------------|----------------------------------------|-------------|-------------|
| 모델 성능 개선          | AUC 점수 0.85 이상 달성                | 이지훈      | 2025-09-01 |
| 데이터 정제 프로세스 확립 | 정제된 데이터셋 1000건 확보          | 김하늘      | 2025-09-02 |
| API 문서화              | 모든 API 엔드포인트 문서화 완료        | 박지민      | 2025-09-03 |

## 2. 팀원별 주요 작업
### 이지훈
- **작업**: 모델 성능 개선을 위한 하이퍼파라미터 튜닝
  - **의존성**: 데이터셋 업데이트 완료 필요
  - **리스크**: 성능 개선이 예상보다 낮을 경우 재조정 필요

### 김하늘
- **작업**: 데이터 정제 작업 및 품질 검증
  - **의존성**: 기존 데이터셋의 품질 문제 해결 필요
  - **리스크**: 정제 과정에서 데이터 손실 발생 가능성
```

✔️ 데이터 양

- 전체 수집 데이터 건수:
  - **구글 API 문서**: 약 2000개 문서 (txt 기준)
  - **회사 내부 문서**: 60개의 txt 문서 (각 부서별 15개씩)

✔️ 저장 위치 및 포맷

- **구글 API 문서, 회사 내부 문서**
  - 저장 경로: SKN14-Final-1Team
  - 저장 포맷: txt(문서)
  - 인코딩: UTF-8

4. 법적·윤리적 검토

[구글 api 문서]

- 개인정보 포함 여부
  - 미포함 (Google API 문서는 기술 문서로, 개인 식별 정보 없음)

- 비식별화 조치 여부
  - 해당없음 (개인정보가 없으므로 별도의 비식별화 불필요)

- 출처 및 사용권
  - Google API 공식 문서 활용
  - 원문 + QA 데이터셋으로 가공하여 RAG 챗봇 목적으로만 사용

- 공개 여부
  - 내부사용 한정

- 라이선스 또는 약관 검토 여부
  - Google 개발자 문서 이용 약관 및 robots.txt 확인 완료
  - 허용된 범위 내에서만 수집 및 활용

[기업 내부 문서]

- 개인정보 포함 여부
  - 미포함 (프롬프트에서 개인정보 포함을 원천적으로 차단)
  - *금지: 회사 전략/재무 수치/계약 조건/미공개 로드맵/고객 실명·식별정보/개인정보/내부 비공개 URL*

- 출처 및 사용권
  - OpenAI API를 활용해 합성한 자체 생성 문서
  - 외부 저작권 문제 없음, 회사 내부 자산으로만 활용

- 공개 여부
  - 내부 전용 (부서 및 직급별 접근 권한에 따라 제한)

5. 이후 활용 계획

- 원문 문서와 QA 데이터셋을 기반으로 API 챗봇(LLM+RAG) 챗봇 구축
- 자동 크롤링 및 주기적 데이터 갱신을 통해 최신 문서 반영 및 데이터 품질 유지
- 기업 내부 문서 기반으로 사내 내부 문서 챗봇(SLLM+RAG) 구축
- 기업 내부 문서 기반으로 사내 내부 문서 챗봇(SLLM) 파인튜닝 데이터 생성성