SK네트웍스 Family AI 과정 14기

데이터 전처리 인공지능 학습 결과서

산출물 단계	데이터 전처리
평가 산출물	인공지능 학습 결과서
제출 일자	2025-10-02
깃허브 경로	SKN14-Final-1Team
작성 팀원	정민영

[1] 사내 내부 문서 기반 RAG: Qwen 모델 (LoRA 파인튜닝)

1. 학습 개요

1.1 학습 목적

- 회사 내부 문서를 기반으로 한 소형 언어모델(Small Large Language Model) 파인튜닝
- 사내 문서 챗봇 구축을 위한 특화된 모델 개발
- 업무 관련 질문과 일상 질문을 모두 처리할 수 있는 통합 모델 구축

1.2 학습 대상 모델

Qwen3-8B: 메인 학습 모델

Qwen2.5-7B-Instruct: 비교 모델

1.3 학습 데이터

- 데이터셋: qwen3_company_train_dataset_combined.json
- 데이터 구조: 대화 형태의 메시지 데이터
- 팀별 분류: Backend, Frontend, Data_AI, CTO
- 말투 변형: 정중체와 반말체 각각 포함

2. 학습 설정

2.1 하이퍼파라미터

항목	값
학습 에포크	3 epochs
배치 크기	4 (per_device_train_batch_size)
그래디언트 누적	2 steps
학습률	1e-4
최적화기	adamw_torch_fused
데이터 타입	bfloat16
최대 시퀀스 길이	8192

2.2 LoRA 설정

항목	값
LoRA 알파	32
LoRA 드롭아웃	0.1
LoRA 랭크	8
타겟 모듈	["q_proj", "v_proj"]
바이어스	none

2.3 학습 최적화

- 그래디언트 체크포인팅: True (메모리 절약)
- 그래디언트 클리핑: 0.3
- 워밍업 비율: 0.03
- 학습률 스케줄러: constant

3. 학습 과정

3.1 데이터 전처리

- Chat 템플릿 적용: Qwen 표준 템플릿 사용
- 토큰화: 최대 8192 토큰으로 제한
- 레이블링: Assistant 응답 부분만 학습 대상으로 설정
- 패딩: 배치 내 최대 길이에 맞춰 패딩 적용

3.2 학습 모니터링

- 로깅 주기: 10 steps
- 모델 저장: 50 steps마다 체크포인트 저장
- 출력 디렉토리: qwen3-8b-informal-formal

4. 성능 평가 결과

4.1 TOOL CALL 멀티턴 성능 평가

평가 데이터: 학습 데이터와 동일한 방식으로 내용만 다른 테스트 데이터셋 생성

평가 기준: tool_selection, params_selection, params_value_similarity

모델	tool_selection	params_selection	params_value_similarity
Qwen3-8B (기본)	79.22%	79.22%	77.21%
Qwen2.5-7B (기본)	25.97%	25.97%	67.33%
Qwen3-8B (파인튜닝)	98.05%	98.05%	88.50%
Qwen2.5-7B (파인튜닝)	99.68%	99.68%	87.55%

4.2 RAG 평가

평가 방식: 자체 제작 데이터셋(55개) + LLM 활용

모델	context_recall	faithfulness	factual_correctness(f1)
Qwen2.5-7B (파인튜닝)	0.7697	0.7992	0.3191
Qwen3-8B (파인튜닝)	0.9273	0.8614	0.3709

자체 정량 RAG 평가 결과:

모델	정확도	재현율	구체성	평균
Qwen2.5-7B (파인튜닝)	67.27	70.91	55.76	64.65
Qwen3-8B (파인튜닝)	70.91	74.55	65.45	70.30

5. 기술적 특징

5.1 메모리 최적화

- bfloat16 사용으로 메모리 절약
- 그래디언트 체크포인팅으로 대용량 모델 학습 가능
- LoRA 기반 효율적 파인튜닝

5.2 대화 처리 능력

- Chat 템플릿 기반 구조화된 대화 처리
- 시스템 메시지와 사용자 메시지 구분
- Assistant 응답만 정확히 라벨링해 학습

5.3 도구 호출 기능

- TOOL CALL / TOOL RESPONSE 구조 학습
- 팀별 특화 검색 도구 활용
- 문서 검색 기반 정확한 답변 생성

6. 학습 성과 분석

6.1 베이스 모델 대비 멀티턴 TOOL CALL 성능 개선

Qwen2.5-7B: 25.97% → 99.68% (+73.71%p)

Qwen3-8B: 79.22% → 98.05% (+18.83%p)

파인튜닝 후: Qwen2.5-7B는 tool_selection이 1% 높고, Qwen3-8B는 value_similarity가 1% 높음

6.2 RAG 성능 비교

Qwen3-8B 파인튜닝 모델이 모든 지표에서 우수

context_recall: 0.7697(qwen2.5-7b) vs 0.9273(qwen3-8b)

faithfulness: 0.7992(qwen2.5-7b) vs 0.8614(qwen3-8b)

factual_correctness(f1): 0.3191(qwen2.5-7b) vs 0.3709(qwen3-8b)

자체 정량적 RAG 평가: Qwen2.5-7B [64.65] vs Qwen3-8B [70.30]

6.3 최종 모델 선정

TOOL CALL 성능은 두 모델 모두 충분

RAG 성능은 Qwen3-8B가 우수

최종 선정 모델: Qwen3-8B 파인튜닝 모델

7. 활용 방안

7.1 사내 문서 챗봇

- 팀별 특화 문서 검색 서비스
- 정확한 RAG 기반 업무 답변
- 일상 질문에도 자연스러운 대화 가능
- 내부 지식 베이스 활용

7.2 추가 개발 방향

- 더 다양한 질문 유형 대응
- 실시간 문서 업데이트 RAG 반영
- 사용자 피드백 기반 개선

8. 결론

Qwen3-8B 파인튜닝을 통해 사내 문서 기반 전문 챗봇을 성공적으로 구축하였습니다..

주요 성과:

- TOOL CALL 성능 대폭 향상 (Qwen2.5-7B: +73.71%p, Qwen3-8B: +18.83%p)
- RAG 성능에서 Qwen3-8B가 가장 우수 (평균 70.30)
- 멀티턴 대화에서 안정적 TOOL CALL 처리

최종 선정 모델: Qwen3-8B 파인튜닝 모델

[2] LangGraph 기반 멀티모달 RAG 챗봇:

GPT-4 + 하이브리드 검색

2.1 모델 개요 및 목적

모델명: GPT-4(4o, 4o-mini 혼합하여 OpenAI API 사용)

용도: 구글 API 문서 기반 멀티모달 질의응답 시스템

선정 이유:

- 멀티모달 처리에 최적: 스크린샷·다이어그램 등 이미지를 텍스트 문맥과 함께 이해
- 구조화된 출력 신뢰성: JSON 모드/함수호출을 활용해 쿼리 추출·분류에 안정적
- 재현성: temperature=0 설정으로 평가·운영 환경에서 일관된 응답
- 생태계·호환성: OpenAI SDK/도구 호환으로 LangGraph 노드와 자연스럽게 연계
- 성능/비용 밸런스: 일상 질문에는 GPT-4o-mini를 조합하여 지연시간과 비용 최적화
- 엔터프라이즈 활용성: 멀티모달+RAG 시나리오에서 높은 사실 충실도와 안전장치 연계 용이

2.2 아키텍처 및 구성

전체 워크플로우:

이미지 분석 → 질문 분류 → 쿼리 추출/분리 → LLM 툴 호출 → 하이브리드 검색 → 답변 생성 → 품질 평가 → (품질 평가에서 'BAD' 나오면) 재검색 후 다시 답변

핵심 구성 요소:

구성 요소	설명
멀티모달 입력 처리	GPT-4o API를 통한 이미지 분석 및 텍스트 통합
지능형 질문 분류	api(구글 API/기술), basic(일상), none(답변불가) 3단계 분류
LLM 툴 호출 시스템	11개 구글 API 태그 중 적절한 태그 자동 선택하여 검색

하이브리드 검색	Chroma + BGE-m3 임베딩(가중치 0.8) & BM25 키워드 검색(가중치 0.2)
재시도 검색 전략	초기 검색(text_k=5, qa_k=20) → 재검색(text_k=15, qa_k=30)

2.3 파라미터 및 설정

모델 및 검색 관련 주요 설정:

항목	설정
메인 모델	GPT-4o (temperature=0)
분류 모델	GPT-4o(temperature=0)
쿼리 추출	GPT-4o (JSON 모드)
품질 평가	GPT-4.1 (temperature=0)
임베딩 모델	BAAI/bge-m3 (normalize_embeddings=True)
벡터 DB	Chroma (원문/QA)
BM25 인덱스	태그별 사전 구축 및 캐싱(pkl파일)
지원 API	11개 구글 API (Maps, Gmail, Drive, Calendar 등)
메모리	MemorySaver (대화 상태 유지)
최대 재시도	1회 (품질 평가 기반)

히스토리 길이	최근 4개 메시지

2.4 주요 기능 및 성능

멀티모달 처리:

- 이미지 업로드 시 자동 분석 및 텍스트 통합
- 이미지-텍스트 연관 질문 처리 가능
- S3 기반 채팅 이미지 저장 및 URL 관리

지능형 검색:

- LLM이 자동으로 API 태그를 선택하여 검색 실행

품질 보장:

- 답변 품질 자동 평가 (good/bad)
- 부정적/회피적 답변 자동 감지
- 대체 쿼리 생성 및 재검색

활용 사례:

- 이 스크린샷에서 나오는 Drive API 오류 해결법은?
- Gmail API에서 라벨별 메일 필터링하는 방법
- BigQuery 데이터셋 생성 시 권한 설정

2.5 시연 예시

입력: 사용자가 Drive API 오류 스크린샷과 함께 “이 오류 어떻게 해결해?”

처리 과정:

1. 이미지 분석: “ google drive api에 대한 403 권한 오류가 나와있는 이미지, insufficient permissions 에러 메세지”
2. 질문 분류: api (구글 API 관련)

3. 쿼리 추출: Drive API 권한 오류 해결, 403 insufficient permissions
4. LLM 툴 호출: drive 태그 선택하여 vector_search_tool 호출
5. 하이브리드 검색: drive 태그로 필터링된 문서 검색
6. 답변 생성: 구체적인 해결 방법 제시
7. 품질 평가: good (구체적 정보 제공)

출력:

이 오류는 Drive API 접근 권한이 부족해서 발생합니다.

해결 방법:

1) Google Cloud Console에서 Drive API 활성화 확인

2) 서비스 계정에 적절한 IAM 역할 부여

3) OAuth 스코프에 'https://www.googleapis.com/auth/drive' 포함

2.6 향후 개선 계획

검색 고도화:

- 시맨틱 캐시 도입으로 응답 속도 개선
- Cross-encoder 리랭킹 추가
- 다국어 쿼리 지원 확장

워크플로우 확장:

- 코드 생성 전용 노드 분기 추가
- API 테스트 결과 연동

2.7 LangGraph 노드 구조 발전 과정

VER-1. 기본 검색 모델

- 구조: 단일 노드 구조

- 워크플로우: 질문 → 벡터 DB 검색 → 답변 생성
- 노드 구성: basic_langgraph_node 단일 노드
- 특징: 기본적인 RAG 구조, 쿼리 분리 없음, QA 벡터 DB 사용

VER-2. 쿼리 분리 모델

- 구조: 3단계 파이프라인
- 워크플로우: 질문 히스토리 통합 → 쿼리 분리 → 벡터 DB 검색 → s답변 생성
- 노드 구성: extract_queries → split_queries → basic_langgraph_node
- 특징: 대화 맥락을 고려한 쿼리 정제 기능 추가, QA 벡터 DB 사용

VER-3. 셀프 쿼리 리트리버 모델

- 구조: 쿼리 분리 모델과 동일한 3단계 파이프라인
- 워크플로우: 질문 히스토리 통합 → 쿼리 분리 → 벡터 DB 검색(셀프 쿼리 리트리버) → 답변 생성
- 노드 구성: extract_queries → split_queries → basic_langgraph_node
- 특징: 벡터 DB 검색 시 셀프 쿼리 리트리버로 API 주제 메타필터 자동 적용, QA 벡터 DB 사용

VER-4. 멀티모달 + 분류 모델

- 구조: 조건부 분기 구조
- 워크플로우: 이미지 분석 → 질문 분류 → (api/basic/none) 분기 → 쿼리 추출 → 검색 → 답변 생성
- 노드 구성: analyze_image → classify → extract_queries → split_queries → basic_langgraph_node
- 특징: GPT-4o 기반 이미지 분석, api/basic/none 3단계 질문 분류, QA 벡터 DB 사용

VER-5. 최종 완성 모델

- 구조: 복합 조건부 분기 + 품질 평가 + 재시도 메커니즘
- 워크플로우: 이미지 분석 → 질문 분류 → 쿼리 추출 → LLM 툴 호출(메타 필터링 적용) → 하이브리드 검색 → 답변 생성 → 품질 평가 → (최종 답변/재검색)

- 노드 구성: analyze_image → classify → extract_queries → split_queries → tool_based_search_node → basic_langgraph_node → evaluate_answer_node → generate_alternative_queries
- 특징: LLM 툴 호출, 하이브리드 검색, 답변 품질 자동 평가, 재시도, 원문/QA 벡터 DB 모두 사용

RAGAS 평가 결과 (버전별 성능 비교):

버전	Context Recall	Faithfulness	Factual Correctness	특징
VER-1	0.6520	0.7354	0.4940	기본 RAG 구조
VER-2	0.6422	0.7623	0.4837	쿼리 분리 추가
VER-3	0.6617	0.8071	0.5150	쿼리 분리 최적화
VER-4	0.4950	0.6062	0.3940	멀티모달 + 분류
VER-5	0.9000	0.9274	0.6940	최종 완성 모델

2.8 최종 모델 성능 요약

지표	값
Context Recall	0.9000
Faithfulness	0.9274
Factual Correctness	0.6940

실제 운영 환경 적용:

- Django 웹 애플리케이션 통합 완료
- apichat 앱의 utils 모듈로 구현

· 실시간 대화형 인터페이스 제공

부록

- Qwen3-8B LoRA 학습 로그

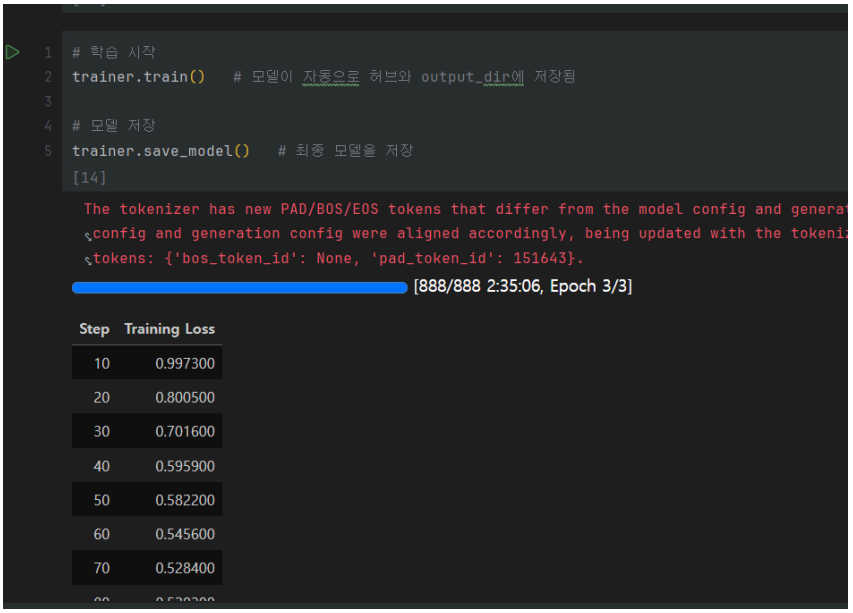

```
# 학습 시작
trainer.train()   # 모델이 자동으로 허브와 output_dir에 저장됨

# 모델 저장
trainer.save_model()   # 최종 모델을 저장
[14]
```

```
The tokenizer has new PAD/BOS/EOS tokens that differ from the model config and genera
config and generation config were aligned accordingly, being updated with the tokeni
tokens: {'bos_token_id': None, 'pad_token_id': 151643}.
```

[888/888 2:35:06, Epoch 3/3]

Step	Training Loss
10	0.997300
20	0.800500
30	0.701600
40	0.595900
50	0.582200
60	0.545600
70	0.528400

- QWEN2.5-7B LoRA 학습 로그

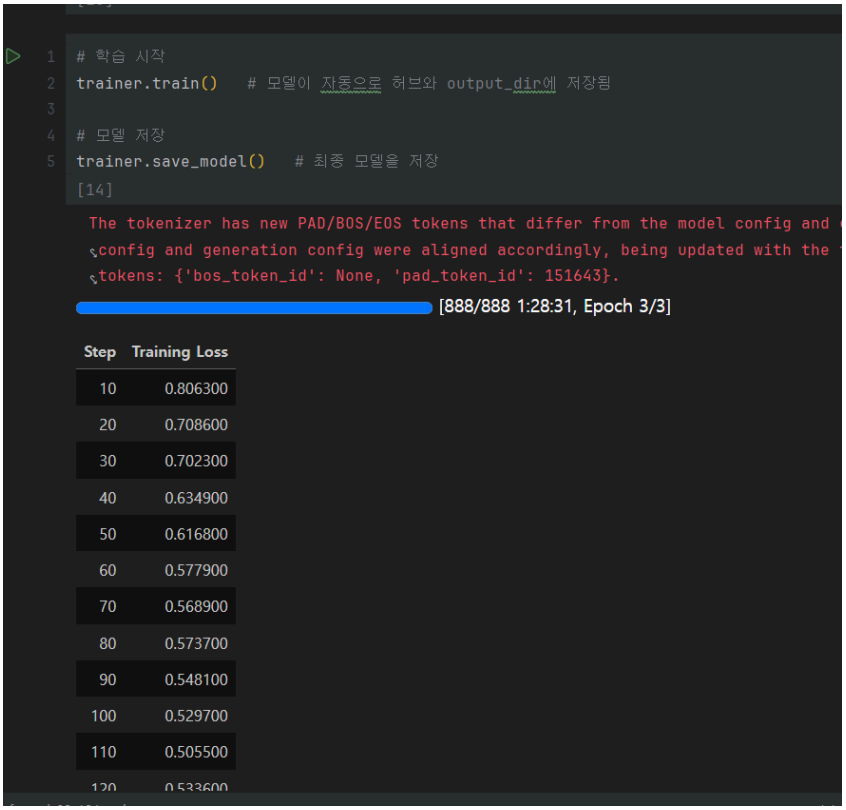

```
# 학습 시작
trainer.train()    # 모델이 자동으로 허브와 output_dir에 저장됨

# 모델 저장
trainer.save_model()    # 최종 모델을 저장
[14]
The tokenizer has new PAD/BOS/EOS tokens that differ from the model config and
config and generation config were aligned accordingly, being updated with the
tokens: {'bos_token_id': None, 'pad_token_id': 151643}.
[888/888 1:28:31, Epoch 3/3]
```

Step	Training Loss
10	0.806300
20	0.708600
30	0.702300
40	0.634900
50	0.616800
60	0.577900
70	0.568900
80	0.573700
90	0.548100
100	0.529700
110	0.505500
120	0.533600

- **QWEN 모델 파인튜닝 학습 코드 스크립트:** https://github.com/skn-ai14-250409/SKN14-Final-1Team-AI/tree/docs/SLLM_FINETUNING/250919
- **Qwen 모델 학습 데이터(허깅페이스) :** https://huggingface.co/datasets/SKN14-Final-1Team/qwen-finetuning-data-ko-250919
- **학습된 QWEN2.5-7B-INSTRUCT 모델(허깅페이스) :** https://huggingface.co/SKN14-Final-1Team/qwen2.5-7b-informal-formal-merged-09-19
- **학습된 QWEN3-8B 모델(허깅페이스) :** https://huggingface.co/SKN14-Final-1Team/qwen3-8b-informal-formal-merged-09-19
- **API 챗봇 LLM LANGGRAPH 소프트웨어(DJANGO 웹 어플리케이션 안에 위치) :** https://github.com/skn-ai14-250409/SKN14-Final-1Team-Web/tree/develop/apichat/utils
- **API 챗봇 LLM LANGGRAPH에서 사용하는 qa셋 데이터(허깅페이스) :** SKN14-Final-1Team/google-api-qa-data-ko · Datasets at Hugging Face